

مدل های مولد عمیق
دکتر امینی



دانشگاه صنعتی شریف

دانشکده: مهندسی برق

امیر کوشان فتاح حصاری ۴۰۱۱۰۲۱۹۱

تمرین سری پنچ

۲۳ دی ۱۴۰۴



مدل های مولد عمیق

تمرین سری پنجم

امیر کوشان فتاح حصاری ۴۰۱۱۰۲۱۹۱

فهرست مطالب

فهرست مطالب

Ergodicity سوال یک : شرایط

بخش اول

اثر هر کدام از شرایط بر روی سмпiling

بخش دوم : موازنه تفصیلی (Detailed Balance)

سوال اول

سوال دوم

Score-Matching انواع

بخش اول

a

b

بخش دوم

a

b

* بخش سوم

a

b

c

d

مدل های Score-Based

سوال اول

سوال دوم

سوال سوم

سوال چهارم

مدل های Energy-Based

سوال اول

سوال دوم

سوال سوم


سوال پنجم

سوال یک : شرایط Ergodicity

بخش اول

اثر هر کدام از شرایط بر روی سمپلینگ

۱. غیر کاهشی بودن (irreducible): یک شرط لازم برای وجود یک توزیع استیشنری یکتا (Stationary) غیر کاهشی بودن زنجیره مارکف ما میباشد یعنی بتوان از هر استیت به استیت دیگه برسیم. هدف نهایی ما هم در MCMC رسیدن به این توزیع نهایی هست. به عنوان مشکل احتمالی نمودار زیر را در نظر بگیرید.



اگر از حالت ۴ شروع کنیم همیشه در این حالت میمونیم. پس یک توزیع استیشنری میتواند $\pi = (0, 0, 0, 1)$ باشد. همچنین اگر از یکی از دو حالت ۱ و ۲ شروع کنیم بین این دو نوسان میکنیم. پس یک توزیع استیشنری دیگر نیز میتواند $\pi = (0.5, 0.5, 0, 0)$ باشد. اگر هم از حالت ۳ شروع کنیم ممکن است به هر کدام از دو توزیع بالا برسیم. برای جلوگیری از این مشکل، یعنی غیر یکتا بودن توزیع نهایی یا همون (target distribution) زنجیره مارکف ما باید غیر کاهشی باشد، یعنی بتوان از هر حالت به هر حالت دیگری رسید.

۲. aperiodic بودن: برای یک حالت پیودش به شکل زیر تعریف می شود:

$$d(x) = \gcd\{n \geq 1 : P^n(x, x) > 0\}$$

یک زنجیره مارکف aperiodic هست اگر $d(x) = 1$ باشد. یک شرط کافی در این زمینه وجود حلقه برگشتی به خود حالت هست. اهمیت این مورد در این هست که اگر زنجیر مارکف ما aperiodic باشد توزیع در حد ما به توزیع stationary همگرا میشود که یکتا هست و در MCMC دنبال رسیدن به این توزیع هستیم. اگر زنجیر مارکف ما داری این خاصیت نباشد باز هم ممکن هست که یک توزیع stationary یکتا وجود داشته باشد اما $P^n(x, \cdot)$ در حالت کلی به آن نمیرسد.

۳. positive recurrent: یک فاکتور دیگه برای وجود limiting distribution ای که برابر با π یعنی توزیع استیشنری یکتامون هست باید در نظر بگیریم، بازگشتی بودن زنجیرمون هست. همچنین زمان بازگشت به یک حالت خاص باید محدود باشد تا توزیع π بتواند وجود داشته باشد.

*: همچنین میگیریم یک حالت ergodic هست اگر aperiodic و positive recurrent باشد.

یک مشکلی که ممکن است پیش بیاید اگر زنجیر مارکف ما positive recurrent نباشد به معنی عدم وجود یک توزیع ثابت نهایی هست. به عنوان مثال یک رندوم واک معمولی را بر روی اعداد صحیح در نظر بگیرید $\mathcal{X} = \{\dots, -2, -1, 0, 1, 2, \dots\}$. اگر $A_{i,i+1} = p$ احتمال حرکت به راست و $A_{i,i-1} = 1 - p$ احتمال حرکت به چپ باشد و از $X_1 = 0$ شروع کنیم:

(آ) اگر $p > 0.5$ به بی نهایت میرویم و تضمینی برای برگشت نیست.

(ب) اگر $p < 0.5$ باشد به منفی بینهایت میروود و باز تضمینی برای برگشت به حالت اولیه نیست.

(ج) اگر $p = 0.5$ باشد آنگاه با احتمال یک به حالت اولیه برمیگردیم ولی زمان برگشتمون بی نهایت هست و نمیتوانیم توزیع ثابت نهایی داشته باشیم.

بخش دوم : موازنه تفصیلی (Detailed Balance)

سوال اول

اگر یک زنجیره مارکف با ماتریس گذر A که در اینجا P هست در موازنه تفصیلی به شکل زیر صدق کند :

$$\pi_i A_{ij} = \pi_j A_{ji} \rightarrow \pi(x)P(x, y) = \pi(y)P(y, x)$$

آنگاه توزیع π یک توزیع ثابت (stationary) برای زنجیره فوق می باشد.

اثبات این قضیه نیز ساده هست :

$$\sum_j \pi_i A_{ij} = \sum_i \pi_j A_{ji} = \pi_j \sum_i A_{ji} = \pi_j$$

$$\Rightarrow \pi = A\pi$$

پس این رابطه وجود یک توزیع stationary را گارانتی میکند.

سوال دوم

این ساختار تضمین میکند که π توزیع یکتا stationary برای زنجیره MH ما هست.

اثبات

$$P_{MH}(y, x) = \begin{cases} q(y, x)\alpha(y, x) & \text{if } x \neq y \\ q(x, x) + \sum_{x \neq y} q(y, x)(1 - \alpha(y, x)) & \text{otherwise} \end{cases}$$

ماتریس گذر زنجیره ما به شکل بالا تعریف میشود. یا در مرحله بعد حالت y پیشنهاد میشود و با احتمال α قبول میشود و میرویم به اون حالت. یا حالت جدید همین حالت الان ما خواهد بود یا حالت جدید پیشنهاد میشود ولی با احتمال $1 - \alpha$ رد میشود. حال درون α دو حالت داریم.

۱. یا

$$\pi(y)q(x, y) > \pi(x)q(y, x)$$

۲. یا

$$\pi(y)q(x, y) \leq \pi(x)q(y, x)$$

با فرض حالت دوم جلو میرویم. پس داریم

$$\alpha(y, x) = \min(1, \underbrace{\frac{\pi(y)q(x, y)}{\pi(x)q(y, x)}}_{<1}) < 1 \Rightarrow \alpha(x, y) = \min(1, \underbrace{\frac{\pi(x)q(y, x)}{\pi(y)q(x, y)}}_{\geq 1}) = 1$$

$$\alpha = \min(1, \frac{\pi(y)q(x, y)}{\pi(x)q(y, x)} < 1) = \frac{\pi(y)q(x, y)}{\pi(x)q(y, x)}$$

$$P_{MH}(y, x) = q(y, x)\alpha(y, x) = \frac{\pi(y)}{\pi(x)}q(x, y) \Rightarrow P_{MH}(y, x)\pi(x) = \pi(y)q(x, y)$$

$$\xrightarrow{*q(x, y) \times \alpha(x, y) = q(x, y) \times 1 = P_{MH}(x, y)} P_{MH}(y, x)\pi(x) = P_{MH}(x, y)\pi(y) \forall x, y$$

چون موازنه تفصیلی برقرار هست نسبت به توزیع π با ماتریس گذر P_{MH} پس توزیع π stationary یکتا ما هست.

انواع Score-Matching

بخش اول

a

از قضیه اساسی حساب دیفرانسیل داریم که :

$$\int_b^a f'(x)dx = f(a) - f(b)$$

حال داریم :

$$\begin{aligned} h(\mathbf{x}) &= f(\mathbf{x})g(\mathbf{x}) \\ \frac{\partial h(\mathbf{x})}{\partial x_i} &= \frac{\partial f(\mathbf{x})g(\mathbf{x})}{\partial x_i} = \frac{\partial f(\mathbf{x})}{\partial x_i}g(\mathbf{x}) + f(\mathbf{x})\frac{\partial g(\mathbf{x})}{\partial x_i} \\ \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{x})g(\mathbf{x})}{\partial x_i} dx_i &= \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{x})}{\partial x_i}g(\mathbf{x}) + f(\mathbf{x})\frac{\partial g(\mathbf{x})}{\partial x_i} \\ f(\mathbf{x}_{-i}, x_i)g(\mathbf{x}_{-i}, x_i) \Big|_{-\infty}^{\infty} &= \lim_{a \rightarrow \infty, b \rightarrow -\infty} f(\mathbf{x}_{-i}, a)g(\mathbf{x}_{-i}, a) - f(\mathbf{x}_{-i}, b)g(\mathbf{x}_{-i}, b) \\ &= \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{x})}{\partial x_i}g(\mathbf{x}) + f(\mathbf{x})\frac{\partial g(\mathbf{x})}{\partial x_i} \end{aligned}$$

$$\lim_{a \rightarrow \infty, b \rightarrow -\infty} f(\mathbf{x}_{-i}, a)g(\mathbf{x}_{-i}, a) - f(\mathbf{x}_{-i}, b)g(\mathbf{x}_{-i}, b) = \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{x})}{\partial x_i}g(\mathbf{x}) + f(\mathbf{x})\frac{\partial g(\mathbf{x})}{\partial x_i}$$

b

$$\begin{aligned} L_{ESM}(\theta) &= \frac{1}{2} \mathbb{E}_{x \sim p_{data}} [\|s_{\theta}(x) - s_{data}(x)\|^2] \\ &= \int p_{data}(x) \left(\frac{1}{2} \|s_{\theta}(x)\|^2 + \frac{1}{2} \|s_{data}(x)\|^2 - s_{\theta}(x)^{\top} s_{data}(x) \right) dx \\ &= \frac{1}{2} \int \sum_i s_{\theta}(x_i)^2 p_{data}(x) - * \sum_i \int p_{data}(x) s_{\theta}(x_i) s_{data}(x_i) + \underbrace{\int \frac{1}{2} \|s_{data}(x)\|^2 p_{data}(x) dx}_{\text{constant wrt } \theta} \end{aligned}$$

$$* - \int p_{data}(x) s_{\theta}(x_i) s_{data}(x_i) = - \int p_{data}(x) s_{\theta}(x_i) \frac{\partial \log p_{data}(x)}{\partial x_i} = - \int s_{\theta}(x_i) \frac{\partial p_{data}(x)}{\partial x_i}$$

با فرض گفته شده در صورت سوال و لم بخش اول داریم :

$$\lim_{\|x\|_p \rightarrow \infty} p_{data}(x) s_{\theta}(x) \rightarrow 0$$

$$\begin{aligned} \Rightarrow \lim_{\|x\|_p \rightarrow \infty} p_{data}(x) s_{\theta}(x) - \lim_{\|x\|_p \rightarrow -\infty} p_{data}(x) s_{\theta}(x) &= \sum_i \int s_{\theta}(x_i) \frac{\partial p_{data}(x)}{\partial x_i} + \int p_{data}(x) \frac{\partial s_{\theta}(x_i)}{\partial x_i} \\ - \sum_i \int s_{\theta}(x_i) \frac{\partial p_{data}(x)}{\partial x_i} &= \sum_i \int p_{data}(x) \frac{\partial s_{\theta}(x_i)}{\partial x_i} = \int p_{data}(x) \text{Tr}(\nabla_x s_{\theta}(x)) \end{aligned}$$

$$\begin{aligned}
L_{ESM}(\theta) &= \frac{1}{2} \mathbb{E}_{x \sim p_{data}} [\|s_{\theta}(x) - s_{data}(x)\|^2] = \frac{1}{2} \int \sum_i s_{\theta}(x_i)^2 p_{data}(x) \\
&\quad + \int p_{data}(x) \text{Tr}(\nabla_x s_{\theta}(x)) + C \\
&= \mathbb{E}_{x \sim p_{data}} \left[\frac{1}{2} \|s_{\theta}(x)\|_2^2 + \text{Tr}(\nabla_x s_{\theta}(x)) \right] + C = L_{ISM}(\theta) + C
\end{aligned}$$

بخش دوم

a

$$\begin{aligned}
L_{ESM, q_{\sigma}}(\theta) &= \mathbb{E}_{\tilde{x} \sim q_{\sigma}} \left[\frac{1}{2} \|s_{\theta}(\tilde{x}) - \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x})\|_2^2 \right] \\
&= \mathbb{E}_{\tilde{x} \sim q_{\sigma}} \left[\frac{1}{2} \|s_{\theta}(\tilde{x})\|_2^2 + \frac{1}{2} \|\nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x})\|_2^2 - \langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}) \rangle \right] \\
&= \mathbb{E}_{\tilde{x} \sim q_{\sigma}} \left[\frac{1}{2} \|s_{\theta}(\tilde{x})\|_2^2 - \langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}) \rangle \right] + \text{constant wrt } \theta
\end{aligned}$$

$$\begin{aligned}
S(\theta) &= \mathbb{E}_{\tilde{x} \sim q_{\sigma}} [\langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}) \rangle] = \int q_{\sigma}(\tilde{x}) \langle s_{\theta}(\tilde{x}), \frac{\nabla_{\tilde{x}} q_{\sigma}(\tilde{x})}{q_{\sigma}(\tilde{x})} \rangle d\tilde{x} \\
&= \int \langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} q_{\sigma}(\tilde{x}) \rangle d\tilde{x} = \int \langle s_{\theta}(\tilde{x}), \int p_{data}(x) \nabla_{\tilde{x}} q_{\sigma}(\tilde{x}|x) dx \rangle d\tilde{x} \\
&= \int \langle s_{\theta}(\tilde{x}), \int \underbrace{p_{data}(x) q_{\sigma}(\tilde{x}|x)}_{q_{\sigma}(\tilde{x}, x)} \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}|x) dx \rangle d\tilde{x} \\
&= \int \int q_{\sigma}(x, \tilde{x}) \langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}|x) \rangle dx d\tilde{x} = \mathbb{E}_{(\tilde{x}, x) \sim q_{\sigma}(\tilde{x}, x)} [\langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}|x) \rangle]
\end{aligned}$$

b

$$\begin{aligned}
L_{ESM, q_{\sigma}}(\theta) &= \mathbb{E}_{\tilde{x} \sim q_{\sigma}} \left[\frac{1}{2} \|s_{\theta}(\tilde{x})\|_2^2 \right] - S(\theta) + \underbrace{\text{constant wrt } \theta}_{C_1} \\
L_{DSM, q_{\sigma}}(\theta) &= \mathbb{E}_{(x, \tilde{x}) \sim q_{\sigma}(x, \tilde{x})} \left[\frac{1}{2} \|s_{\theta}(\tilde{x})\|_2^2 + \underbrace{\frac{1}{2} \|\nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}|x)\|_2^2 - \langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}|x) \rangle}_{\text{constat wrt } \theta} \right] \\
&= \underbrace{\mathbb{E}_{(\tilde{x}, x) \sim q_{\sigma}(x, \tilde{x})} \left[\frac{1}{2} \|s_{\theta}(\tilde{x})\|_2^2 \right]}_{x \text{ integrates out}} - \underbrace{\mathbb{E}_{(\tilde{x}, x) \sim q_{\sigma}(\tilde{x}, x)} [\langle s_{\theta}(\tilde{x}), \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}|x) \rangle]}_{S(\theta)} + \text{constant wrt } \theta \\
&= \mathbb{E}_{\tilde{x} \sim q_{\sigma}(\tilde{x})} \left[\frac{1}{2} \|s_{\theta}(\tilde{x})\|_2^2 \right] - S(\theta) + \underbrace{\text{constant wrt } \theta}_{C_2}
\end{aligned}$$

$$C_1 - C_2 = C_3 \Rightarrow L_{ESM, q_{\sigma}}(\theta) = L_{DSM, q_{\sigma}} + C_3$$

* بخش سوم

a

میدانیم که :

$$L_{ESSM}(\theta) = \frac{1}{2} \mathbb{E}_{v \sim p_v} \mathbb{E}_{x \sim p_{data}} [\|\mathbf{v}^\top s_\theta(x) - \mathbf{v}^\top s_{data}(x)\|_2^2]$$

$$= \frac{1}{2} \mathbb{E}_{v \sim p_v, x \sim p_{data}} [\|\mathbf{v}^\top s_\theta(x)\|_2^2 + \|\mathbf{v}^\top s_{data}(x)\|_2^2 - (\mathbf{v}^\top s_\theta(x))(\mathbf{v}^\top s_{data}(x))]$$

$$(\mathbf{v}^\top s_\theta(x))(\mathbf{v}^\top s_{data}(x)) = [v_1, v_2, \dots, v_d] \begin{bmatrix} s_\theta(x_1) \\ s_\theta(x_2) \\ \vdots \\ s_\theta(x_d) \end{bmatrix} [v_1, v_2, \dots, v_d] \begin{bmatrix} s_{data}(x_1) \\ s_{data}(x_2) \\ \vdots \\ s_{data}(x_d) \end{bmatrix}$$

$$= \sum_{j=1}^d \left(\sum_{i=1}^d v_i s_\theta(x_i) \right) v_j s_{data}(x_j)$$

$$\Rightarrow \mathbb{E}_{v \sim p_v, x \sim p_{data}} \left[\sum_{j=1}^d \left(\sum_{i=1}^d v_i s_\theta(x_i) \right) v_j s_{data}(x_j) \right]$$

$$= \int \int \sum_{j=1}^d \left(\sum_{i=1}^d v_i s_\theta(x_i) \right) v_j s_{data}(x_j) p_{data}(x_j) p_v(v_j) dx_j dv_j$$

$$= \sum_i \sum_j \int \int v_i s_\theta(x_i) v_j \underbrace{s_{data}(x_j) p_{data}(x_j)}_{\frac{\partial p_{data}(x_j)}{\partial x_j}} p_v(v_j) dx_j dv_j$$

$$= \sum_i \sum_j \int \int v_i s_\theta(x_i) \frac{\partial p_{data}(x_j)}{\partial x_j} v_j p_v(v_j) dx_j dv_j$$

با فرض اینکه $\lim_{\|x\| \rightarrow \infty} s_\theta(x) p_{data}(x) = 0$:

$$\int s_\theta(x_i) \frac{\partial p_{data}(x_j)}{\partial x_j} dx_j = - \int p_{data}(x_j) \frac{\partial s_\theta(x_i)}{\partial x_j} dx_j$$

$$- \sum_i \sum_j \int \int v_i s_\theta(x_i) \frac{\partial p_{data}(x_j)}{\partial x_j} v_j p_v(v_j) dx_j dv_j = \sum_i \sum_j \int \int v_i p_{data}(x_j) \frac{\partial s_\theta(x_i)}{\partial x_j} v_j p_v(v_j) dx_j dv_j$$

$$= \int \int \sum_i \sum_j v_i \frac{\partial s_\theta(x_i)}{\partial x_j} v_j p_v(v_j) p_{data}(x_j) dx_j dv_j$$

$$= \int \int \mathbf{v}^\top \nabla_x s_\theta(x) \mathbf{v} p_v(v_j) p_{data}(x_j) dx_j dv_j = \mathbb{E}_{v \sim p_v, x \sim p_{data}} [\mathbf{v}^\top \nabla_x s_\theta(x) \mathbf{v}]$$

$$-\mathbb{E}_{v \sim p_v, x \sim p_{data}} [(\mathbf{v}^\top s_\theta(x))(\mathbf{v}^\top s_{data}(x))] = \mathbb{E}_{v \sim p_v, x \sim p_{data}} [\mathbf{v}^\top \nabla_x s_\theta(x) \mathbf{v}]$$

b

$$\begin{aligned}
L_{ESSM}(\theta) &= \frac{1}{2} \mathbb{E}_{v \sim p_v, x \sim p_{data}} \left[\|\mathbf{v}^\top s_\theta(x)\|_2^2 + \underbrace{\|\mathbf{v}^\top s_{data}(x)\|_2^2}_{\text{constant wrt } \theta} - (\mathbf{v}^\top s_\theta(x))(\mathbf{v}^\top s_{data}(x)) \right] \\
L_{ESSM}(\theta) &= \frac{1}{2} \mathbb{E}_{v \sim p_v, x \sim p_{data}} \left[\|\mathbf{v}^\top s_\theta(x)\|_2^2 - \underbrace{(\mathbf{v}^\top s_\theta(x))(\mathbf{v}^\top s_{data}(x))}_{\text{from a} = \mathbf{v}^\top \nabla_x s_\theta(x) \mathbf{v}} \right] + \text{constant wrt } \theta \\
&= \frac{1}{2} \mathbb{E}_{v \sim p_v, x \sim p_{data}} [\|\mathbf{v}^\top s_\theta(x)\|_2^2 + \mathbf{v}^\top \nabla_x s_\theta(x) \mathbf{v}] + \text{constant wrt } \theta
\end{aligned}$$

$$L_{ESSM}(\theta) = L_{ISSM}(\theta) + C$$

c

حقیقتا بدون هیچگونه منبع ای سخت بود برام!

d

1.

$$\begin{aligned}
L_{ESSM}(\theta) &= \frac{1}{2} \mathbb{E}_{v \sim p_v, x \sim p_{data}} [(v^\top \Delta s(x))^2] \\
&= \frac{1}{2} \mathbb{E}_{v \sim p_v, x \sim p_{data}} [\Delta s(x)^\top v v^\top \Delta s(x)] \\
&= \frac{1}{2} \mathbb{E}_{x \sim p_{data}} \left[\Delta s(x)^\top \underbrace{\mathbb{E}_{v \sim p_v} [v v^\top]}_{I_D} \Delta s(x) \right] \\
&= \frac{1}{2} \mathbb{E}_{x \sim p_{data}} [\Delta s(x)^\top \Delta s(x)] = \frac{1}{2} \mathbb{E}_{x \sim p_{data}} [\|\Delta s(x)\|_2^2] = L_{ESM}(\theta)
\end{aligned}$$

2.

$$\begin{aligned}
\mathbb{E}[v v^\top] &= \begin{cases} \mathbb{E}[v_i^2], & i = j, \\ \mathbb{E}[v_i \cdot v_j], & i \neq j \end{cases} \\
v \sim \text{Rademacher} &\Rightarrow \begin{cases} \mathbb{E}[v_i^2] = P(v_i = 1) \times v_i^2 + P(v_i = -1) \times v_i^2 = 1 \\ \mathbb{E}[v_i \cdot v_j] = -\frac{1}{4} - \frac{1}{4} + \frac{1}{4} + \frac{1}{4} = 0 \end{cases}
\end{aligned}$$

$$\Rightarrow \mathbb{E}[v v^\top] = \begin{cases} 1, & i = j, \\ 0, & i \neq j \end{cases} = I_D$$

$$v \sim \mathcal{N}(v|0, I_D) \Rightarrow C_{vv} = \mathbb{E}[(v - \mathbb{E}[v])(v - \mathbb{E}[v])^\top]$$

$$\mathbb{E}[v] = 0 \Rightarrow C_{vv} = \mathbb{E}[v v^\top] = I_D$$

$$v \sim \mathcal{N}(v|0, I_D) \Rightarrow C_{vv} = \mathbb{E}[v v^\top] = I_D$$

مدل های Score-Based

سوال اول

از جمله مشکلاتی که الگوریتم Langevin Dynamics ممکن است به آنها برخورد عبارتند از :

1. Slow Mixing: ایده اصلی این الگوریتم حرکت به سمت نواحی با احتمال بالاتر با استفاده از اطلاعات تابع score هست، ولی در فضاهای با ابعاد بالا این پروسه میتواند به شدت آرام باشد و به دلیل استفاده از نویز و استوکستیک بودن ممکن است الگوریتم در مینیموم های محلی گیر کند.
2. Noise Schedule: الگوریتم Langevin Dynamics به شدت به نویز حساس هست و باید تنظیم مقدار نویز با دقت انجام شود. روش هایی که برای بهبود این الگوریتم میتوانیم استفاده کنیم عبارت اند از :
 1. کاهش واریانس : با استفاده از تکنیک هایی مانند نمونه گیری مهم و یا روش های بازتوزیع سازی مبتنی بر گرادیان (score). این تکنیک ها باعث کاهش واریانس فرآیند نمونه برداری و امکان استفاده از گام های بزرگتر و همگرایی سریع تر می شوند.
 2. Adaptive Step Size: الگوریتم هایی که به صورت خودکار اندازه گام را بر اساس میزان انحنای محلی تابع گرادیان تنظیم می کنند. در مناطق با انحنای بالا، گام کاهش می یابد و در مناطق صاف، گام افزایش می یابد.
3. SGLD: این روش یک نسخه محبوب از لنگوین داینامیک است که تنها از زیرمجموعه ای از داده ها (یک دسته کوچک) برای محاسبه گرادیان در هر مرحله استفاده می کند. این کار باعث کاهش قابل توجه هزینه محاسباتی و امکان نمونه برداری از مجموعه های داده بسیار بزرگ می شود.
4. Noisy Neural Langevin Dynamics: این رویکرد از قدرت شبکه های عصبی برای یادگیری یک برنامه نویز آموزنده تر استفاده می کند، که منجر به بهبود کارایی نمونه برداری می شود.

سوال دوم

برای ساخت یک مدل شرطی برای تولید نمونه از کلاس های مختلف، می توان از یک مدل $\square\square\square\square-\square\square\square\square$ غیر شرطی از پیش آموزش دیده به همراه یک طبقه بند نرم (soft classifier) استفاده کرد. هدف این است که مدل score-based را با اطلاعات طبقه بندی یاد گرفته شده، هدایت کرده و نمونه هایی تولید کنیم که به احتمال زیاد به کلاس های مورد نظر تعلق داشته باشند. ایده اصلی این است که از گرادیان تابع لگاریتم احتمال (score function) مدل score-based غیر شرطی استفاده کنیم و آن را با یک ترم هدایت کننده (guidance term) بر اساس خروجی طبقه بند نرم ترکیب کنیم. این ترم هدایت کننده، نمونه ها را به سمت فضاهایی که احتمال تعلق به یک کلاس خاص بیشتر است، سوق می دهد.

فرض کنید:

1. x_t نشان دهنده نمونه در زمان t است.
2. ϵ نرخ نویز (noise schedule) است.
3. $s(x_t) = \nabla_x \log p(x_t)$ گرادیان تابع لگاریتم احتمال (score function) مدل score-based غیر شرطی است.
4. $p_c(y|x_t)$ خروجی طبقه بند نرم برای کلاس y با توجه به نمونه x_t است. (یک توزیع احتمال بر روی کلاس ها)
5. β یک ضریب وزن دهی (weighting factor) است که قدرت هدایت شرطی را کنترل می کند.

به روزرسانی نمونه در الگوریتم Langevin dynamics به صورت زیر تغییر می کند:

$$x_{t+1} = x_t + \epsilon s(x_t) + \sqrt{2\epsilon} z_t + \beta \nabla_x \log p_c(y|x_t)$$

که در آن z_t یک نویز تصادفی با توزیع نرمال استاندارد است.

1. عبارت $\epsilon s(x_t)$ نشان دهنده گام تصادفی در جهت گرادیان تابع لگاریتم احتمال است.
2. عبارت $\sqrt{2\epsilon} z_t$ نشان دهنده نویز است که برای جلوگیری از همگرایی سریع و امکان اکتشاف در فضای نمونه ها اضافه می شود.

۳. عبارت $\beta \nabla_x \log p_c(y|x_t)$ ترم هدایت کننده است که نمونه را به سمت فضاهایی که احتمال تعلق به کلاس y بیشتر است، سوق می دهد. مقدار β تعیین می کند که چقدر این هدایت باید قوی باشد.

به این ترتیب، با افزودن این ترم به الگوریتم Langevin dynamics، می توانیم از مدل score-based غیر شرطی برای تولید نمونه هایی استفاده کنیم که به طور خاص به یک یا چند کلاس خاص مرتبط هستند، با هدایت آن ها توسط خروجی طبقه بند نرم.

سوال سوم

در ساخت مدل شرطی با استفاده از روش مطرح شده در قسمت (۲)، نمی توان از یک طبقه بند از پیش آموزش دیده یخ زده frozen pretrained classifier استفاده کرد. این امر به دلایل زیر ضروری است:

۱. عدم تطابق توزیع ها: طبقه بند از پیش آموزش دیده بر روی یک مجموعه داده و یک وظیفه خاص آموزش داده شده است. خروجی های آن ممکن است با توزیع هایی که توسط مدل score-based تولید می شوند، همسو نباشد. ترم هدایت شرطی به خروجی های طبقه بند برای راهنمایی فرآیند نمونه برداری متکی است. یک طبقه بند یخ زده این امکان را فراهم نمی کند.

۲. عدم همسویی با نمونه های تولید شده: مدل score-based نمونه ها را بر اساس توزیع احتمال کلی آن تولید می کند. این نمونه ها ممکن است به طور ذاتی با کلاس هایی که ما علاقه مند به آنها هستیم، همسو نباشند. طبقه بند باید این نمونه ها را به کلاس های مورد نظر نگاشت کند. یک طبقه بند یخ زده این نگاشت را یاد نگرفته است.

۳. اثرگذاری بر Score Function: حتی اگر از یک طبقه بند یخ زده استفاده کنیم، خروجی آن می تواند باعث ایجاد سوگیری در تابع score شود. تابع score باید بازتابی از توزیع احتمال واقعی داده ها باشد. یک طبقه بند یخ زده، آموزش دیده بر روی توزیع متفاوت، می تواند تابع score را فاسد کند و منجر به نتایج ضعیف شود.

طبقه بند شرطی، نقش حیاتی در ترجمه نمونه های غیر شرطی تولید شده توسط مدل score-based به نمونه هایی دارد که به طور دقیق با کلاس های مورد نظر مطابقت دارند. این ترجمه نیازمند سازگاری و تنظیم دقیق طبقه بند با ویژگی های نمونه های تولید شده است، که یک طبقه بند یخ زده فاقد این قابلیت است.

سوال چهارم

تابع هدفی که سعی در بهینه سازی آن داریم به شکل زیر هست ::

$$J(\theta) = \mathbb{E}_{P_{data}} \left[\frac{1}{2} \|s_{\theta}(x)\|_2^2 + \text{tr}(\nabla_x s_{\theta}(x)) \right]$$

۱. عبارت اول به عنوان پهنالی برای انرژی هست. این عبارت اندازه تابع score را جریمه میکند. از آنجایی که تابع اسکور به ناحیه های با احتمال بیشتر اشاره میکند این عبارت اول از به وجود آمدن پیک های تیز جلوگیری میکند.

۲. ترم دوم که درواقع لاپلاسیان $\log p_{data}$ هست خم فضا رو (curvature) را کنترل میکند تا در مد ها یا همان دیتا پوینت ها شکل تابع معقر باشد و ماکسیموم های محلی به وجود بیاید.

مدل های Energy-Based

سوال اول

روش Contrastive Divergence راهی برای تخمین گرادیان لگاریتم تابع درستمایی در حین آموزش مدل های Energy-based هست. در این الگوریتم زنجیره MCMC را از یک نقطه x شروع میکنیم و برای تعدادی گام مشخص ادامه میدهیم. در نهایت میخواهیم تابع هدف زیر را بهینه کنیم:

$$CD_T = D_{\text{KL}}(p_0 || p_\infty) - D_{\text{KL}}(p_T || p_\infty)$$

که در اینجا p_T توزیع تخمین زده شده برای داده x با استفاده از MCMC بعد از T قدم هست و p_0 توزیع داده امون هست. دلیل زمانبر بودن با اینکه حتی برای رسیدن به equilibrium صبر نمیکنیم میتواند به دلایل زیر باشد:

۱. در داخل الگوریتم MCMC یک حلقه سمپلینگ گیز یا Langevin Dynamics نیز قرار میدهیم تا بتوانیم از سمپل های منفی هم بهره ببریم در آموزش. همین باعث کند شدن الگوریتم میشود.

۲. در ابعاد بالا حتی برای چند قدم، اجرا کردن این الگوریتم میتواند از نظر محاسباتی زمانبر باشد.

سوال دوم

یک مزیت نسبت به Metropolis-Hastings این هست که سمپل های $i.i.d$ تولید میکند در حالی که در MH یک زنجیره مارکف داریم که هر سمپل وابسته به سمپل قبل از خود هست.

یک نقطه ضعف نسبت به الگوریتم MH این هست که rejection sampling از نفرین ابعاد رنج میرد. در واقع برای ابعاد بسیار بالا پیدا کردن یک توزیع $q(x)$ و M مناسب که در رابطه $p(x) \leq Mq(x)$ صدق کند به شدت سخت هست چون به ازای انتخاب های بزرگ M احتمال قبولی متناسب با $1/M$ میشود و تقریباً تمام سمپل های پیشنهادی ریجکت میشوند.

سوال سوم

با توجه به توزیع داده شده

$$p(x) = 0.6\mathcal{N}(50, 1) + 0.4\mathcal{N}(0.001, \sigma^2)$$

$$Q(x'|x) = \mathcal{N}(x, 0.5)$$

دلایل کند بودن الگوریتم MH برای سمپل کردن از توزیع بالا:

۱. Mode Isolation: مد ها در $x \approx 0$ و $x \approx 50$ قرار گرفته اند. توزیع پیشنهادی استپ سائز بسیار کوچکی دارد. احتمال اینکه الگوریتم MH یک جامپ از روی ۵۰ واحد فاصله پیشنهاد دهد تا به مد دوم برسیم تقریباً صفر هست.

۲. Poor Mixing: این زنجیره احتمالاً در هر مدی که از آن شروع کند گیر میکند و همین باعث Poor Mixing میشود.

راه حل های پیشنهادی عبارتند از

۱. Parallel Tempering: اجرای چندین زنجیره متفاوت با temperature های مختلف تا فضای احتمالی را صاف کنیم.

۲. از یک مدل پیشنهادی استفاده کنیم که به طور معمول از استپ سائز های بزرگ استفاده میکند تا مانع گیر کردن در یک مد شویم.

سوال پنجم

$$p(z) = \exp(-z), \quad z \geq 0$$

$$p(x|z) = zx \exp\left(-\frac{zx^2}{2}\right), \quad x \geq 0$$

$$p(z|x) = \frac{p(x|z)p(z)}{p(x)} \Rightarrow \log p(z|x) = \log p(x|z) + \log p(z) - \log p(x)$$

$$= \log z + \log x - \frac{zx^2}{2} - z - \log p(x)$$

$$\nabla_z \log p(z|x) = \frac{1}{z} - 1 - \frac{x^2}{2}$$

$$\log q(z|x) = 2 \log \theta + \log z - \theta z, \quad z \geq 0$$

$$\nabla_z \log q(z|x) = \frac{1}{z} - \theta \Rightarrow \|\nabla_z S_p(z|x) - \nabla_z S_q(z|x)\|_2^2 = 0$$

$$\Rightarrow S_p(z|x) - \nabla_z S_q(z|x) = 0$$

$$\frac{1}{z} - 1 - \frac{x^2}{2} - \frac{1}{z} + \theta = 0 \Rightarrow \theta = \frac{x^2}{2} + 1$$

$$\theta = \frac{x^2}{2} + 1$$